

Proposta de Trabalho Prático - Projeto de Agentes de IA - UFMG

Integrantes do grupo:

Francisco Teixeira Rocha Aragão

Thaís Ferreira da Silva

Lorenzo Carneiro Magalhaes

Tomás Lacerda Muniz

Descrição

O problema que será tratado neste trabalho diz respeito à construção de um atendente automatizado para o setor imobiliário. A ideia é construir um atendente que irá fazer o primeiro contato com interessados, fornecer informações, conduzir conversas, qualificar clientes ("leads") e direcionar os usuários aos vendedores disponíveis, tudo de maneira automática.

Objetivo principal: Construção de um atendente automatizado no setor imobiliário com foco em agendar reunião com vendedores. O atendente deve fornecer informações precisas sobre os imóveis de interesse ao usuário, além de conduzir as conversas de maneira natural. Deve ser evitado o envio excessivo de informações, linguagem inapropriada e erros no atendimento.

Ambiente e estrutura do agente

O ambiente em que o agente estará inserido lida com o cenário de muitas pessoas interessadas em imóveis, fazendo perguntas diversas (relacionadas ou não ao tema), mas que na prática, apenas uma pequena parcela está decidida a adquirir um imóvel e avançar na negociação. Para a boa execução da tarefa, o atendente irá atuar por algumas etapas de qualificação dos interessados (funil de vendas):

1. Contato inicial

O atendente deve fazer o primeiro contato dos interessados, se apresentando de maneira cordial e dizendo que pode ajudar no que for necessário em relação ao tema (apresentação imobiliária).

Nessa etapa, o foco é se apresentar e quebrar a barreira inicial. Ao se apresentar e falar sua função, pessoas que chegaram por engano já serão filtradas. Ao mesmo tempo, os que entraram em contato com interesse genuíno, irão apresentar suas dúvidas e iniciar a conversa com o atendente.

2. Informação

Após saber a dúvida do usuário, o atendente deverá então sanar o questionamento da maneira objetiva, apresentando informações sobre os imóveis (como preço, área, valores, prazos relacionados a obras e demais informações do imóvel).

Para isso, o agente contará com base de dados e ferramentas específicas à disposição que permitirão a pesquisa de informações que melhor se adequam à pergunta do usuário. Serão disponibilizados documentos, fotos, vídeos, PDFs, tabelas além de outras mídias que complementam as informações sobre os imóveis.

Essa etapa configura-se como o momento de maior retenção de pessoas, em que os leads que apenas querem tirar uma dúvida rápida, ou buscam apenas conhecer os imóveis (mas sem intenção de compra), terão seus questionamentos resolvidos e a conversa finalizada.

3. Nutrição e Qualificação

Após tirar as primeiras dúvidas, o atendente deve “nutrir” o lead com argumentos de vendas, mostrando diferenciais do imóvel e suas vantagens. Além disso, deve atuar fazendo perguntas de qualificação, identificando o grau de satisfação com a localização, preço e estrutura da residência.

Aqui a conversa não deve ser como um interrogatório. O atendente deve conduzir de maneira suave e entender o grau de maturidade do lead no contexto da venda. Além disso, não deve ser retornado informações excessivas ao cliente, sendo necessário moderação da quantidade de mensagens e perguntas durante essa etapa.

4. Agendamento

Com a conversa fluindo bem, a última etapa é alcançada e o atendente sugere uma reunião com um dos vendedores disponíveis para conhecer mais detalhes, simular a compra ou agendar uma visita ao imóvel.

Essa etapa também representa uma importante etapa do funil, com o agendamento de uma reunião mostrando o interesse genuíno do cliente em adquirir um imóvel.

Dessa forma, como o foco do problema exige conversas contextualizadas, leves, simpáticas e ao mesmo tempo, retornando informações específicas do interesse do usuário, juntamente ao julgamento e qualificação da postura dos leads. Com isso a tarefa será feita com auxílio de LLM e tools em um sistema de agente único, especializado em vendas.

Assim, o modelo vai atuar conduzindo o lead durante todas as etapas do pipeline, além de gerenciar todas as ferramentas disponíveis a sua disposição para sanar dúvidas durante a conversa. O atendente terá comportamento deliberativo, com o modelo utilizado possuindo Reasoning, ou seja, com capacidade de raciocínio, refletindo antes de tomar qualquer ação.

Com isso, podemos formalizar a proposta da seguinte forma:

- Estados

Fluxo de conversa controlado pelo atendente que seguirá um funil de vendas comercial:

Contato inicial -> Informação -> Nutrição / Qualificação -> Agendamento.

Porém outros estados podem ser alcançados dependendo da conversa:

Encerramento: Usuário desistiu da conversa ou não gostou do atendimento

Transferência humana: Antes de chegar ao fim do funil de vendas, o usuário foi transferido a um humano.

- Observações

O atendente terá acesso a diferentes informações:

- Mensagens do usuário
- Histórico da conversa
- Dados recuperados via RAG
- Respostas das ferramentas (tools)

- Ações

Com base nas informações, o agente poderá executar diferentes ações e transitar entre os estados:

- Enviar mensagens textuais
- Consultar informações via RAG
- Enviar mensagens com fontes de mídia
- Realizar perguntas de qualificação
- Sugerir agendamento (finalizando o fluxo de venda)
- Transferir conversa para humano
- Encerrar conversa

Tudo isso vai depender do julgamento do agente, que contará com um prompt delimitando todas essas operações além do seu papel como vendedor no cenário alvo do projeto.

- Decisões

Complementado o que foi dito acima, cabe ao modelo decidir diferentes etapas da conversa:

- Em qual nível o usuário se encontra, para assim, seguir o fluxo de venda ou chamar ferramentas específicas
 - Usuário conhece os imóveis? Está interessado? Se está interessado, tem condições de comprar o imóvel? O usuário planeja comprar agora? O usuário está satisfeito com as opções apresentadas? O agendamento já pode ser marcado? ...
- Identificar o objetivo da mensagem do usuário

- Usuário fez uma pergunta que deve ser respondida usando RAG? A mensagem do usuário está dentro do escopo de atendimento ou deve ser direcionada a um humano? ...

Essas decisões seguem uma política híbrida baseada na interpretação do modelo com as informações da aplicação descritas no prompt, além de regras, como exemplo:

- Se a mensagem fala sobre imóveis -> RAG deve ser acionado
- Se o usuário demonstra interesse e continua seguindo a conversa -> usuário deve avançar no pipeline
- Se toda a etapa do funil de vendas foi seguida e usuário parece qualificado -> agendamento deve ser marcado
- Se a demanda for fora de escopo -> transferir para humano
- Se o usuário não gostar dos imóveis -> atendente deve persuadir cliente e mostrar outras opções para seguir a conversa

Ferramentas Utilizadas

LLM - Anthropic Claude Sonnet 4.6 ou OpenAI GPT - 5.2

Modelos de alta qualidade utilizados para geração de respostas, interpretação de mensagens e tomada de decisão ao longo da conversa. O modelo final ainda será definido durante a implementação do projeto.

Ferramentas - Qdrant, Celery, Redis, FastAPI

Qdrant será utilizado como vector store para busca semântica (RAG). Celery será responsável pelo processamento de tarefas assíncronas. Redis será utilizado como sistema de cache e fila de mensagens. FastAPI será responsável pela interface de comunicação entre os serviços.

Troca de mensagens - Chatwoot e Whatsapp / Meta

O Chatwoot será utilizado como intermediário entre o agente e o WhatsApp, permitindo o envio e recebimento de mensagens.

Deploy - Docker Swarm em VPS

A aplicação será implementada em contêineres orquestrados utilizando Docker Swarm, sendo executada em uma VPS para garantir disponibilidade e acesso externo.

Código e infraestrutura - Python

Python será utilizado como linguagem principal devido à facilidade de integração com as ferramentas adotadas e rapidez no desenvolvimento.

Armazenamento - Cloudflare R2 e PostgreSQL

O Cloudflare R2 será utilizado para armazenamento de arquivos (imagens, vídeos e documentos). O PostgreSQL será utilizado para salvar informações dos usuários e histórico de conversas.

Rag - Recuperação híbrida com embeddings e BM25

Uma estratégia híbrida será utilizada para recuperar informações relevantes sobre os imóveis, combinando busca vetorial (embeddings) com busca textual (BM25). Os documentos serão processados em chunks e, quando necessário, será utilizado OCR (Tesseract) para extração de texto. Os resultados serão combinados com pesos (exemplo: 70% vetorial e 30% textual), que poderão ser ajustados posteriormente via experimentação.

Ferramentas disponibilizadas ao modelo (tools)

O modelo contará com diferentes ferramentas (tools) para sua boa execução.

- Transferência humana: Função chamada pelo atendente quando o usuário quiser falar diretamente com um vendedor, quando precisar negociar valores ou caso possuir alguma demanda fora do padrão.
- Database: Funções para coletar informações dos imóveis. Será necessário a implementação de funções para listar todos os imóveis, além de retornar informações específicas de cada locação. Assim o agente consegue nutrir a conversa, direcionar o usuário ao imóvel mais apropriado além de fornecer detalhes da residência alvo.
- Mensagens: O agente vai precisar de acesso a ferramentas de envio de mensagens, mais especificamente ao envio de texto, fotos, vídeos e documentos. Assim, sempre que o atendente julgar necessário, ele pode retornar conteúdos adicionais ao usuário na conversa para complementar as informações sobre os imóveis e prosseguir com a qualificação.

Base de dados

Lista de documentos com informações sobre imóveis, incluindo links, fotos, vídeos, PDFs, tabelas e informações textuais.

Observação: Os documentos não representam informações reais, apenas dados artificialmente gerados para simular o contexto da aplicação. Dessa forma, os dados já estarão padronizados, em boa qualidade, com conteúdos válidos e não ofensivos. Em aplicações reais, um maior cuidado com os dados seria necessário para evitar propagação de conteúdo malicioso, ou de baixa qualidade.

Segurança e auditoria

Será implementado uma camada de segurança na própria Qdrant ao criar coleções separadas por imobiliárias, isso permite filtrar durante o RAG o ID da imobiliária, evitando que qualquer informação possa ser vazada entre diferentes atendimentos. Além disso, iremos construir uma

camada de moderação usando a OpenAI Moderation API que impede que imagens torpes sejam passadas para frente de acordo com a lei. Contaremos também com um sistema de proteção de prompt, através de um system prompt dynamic build, arquitetura similar a da OpenClaw, que, por mais que não evite totalmente, dificulta muito o acesso a modos danosos da LLM.

Proteções via prompt também serão implementadas, evitando que o atendente siga condutas inadequadas na conversa, além de reforçar o bom comportamento durante a troca de mensagem. Será terminantemente proibido mudanças de instruções de prompt via mensagens de usuário, ou desvio de função (tal comportamento será também barrado via código, evitando que o system prompt do modelo possa ser alterado externamente). O atendente também não possuirá acesso a variáveis de ambiente, segredos ou Chaves de API, evitando vazamento de informações sigilosas.

Todo o processo de conversa e troca de mensagens entre usuário e atendente é salvo na plataforma de mensagens utilizada (Chatwoot). Isso permite a auditoria de cada mensagem, enviada e recebida, além de permitir acesso e controle total de algum humano na conversa, podendo assumir o controle sempre que necessário.

Além disso, o sistema contará com logs, armazenados em arquivos de texto, identificados pelo ID do usuário que envia mensagem, além de possuir o timestamp para facilitar a auditoria de erros ou mau comportamento. Juntamente a isso, alertas podem ser emitidos em plataformas de terceiros, como o Discord, de forma a notificar erros críticos mais facilmente.

Experimentação

Toda a estrutura implementada será testada localmente, sendo verificado as requisições realizadas, logs das funções além do retorno do atendente em diferentes cenários (positivos e negativos). Para isso, diferentes cenários serão mapeados e testados, como:

- Fluxo ótimo do usuário, com mensagens coerentes, perguntas válidas e interesse pelos imóveis
- Fluxo ruim do usuário, com perguntas mal feitas, mensagens sem sentido entre outros problemas
- Falhas de APIs
- Falhas no uso das ferramentas
- Diferentes cenários de vendas, com usuário gostando das opções de imóveis, mas também não se mostrando satisfeito
- Entre outros casos de testes

Esses cenários serão testados principalmente na prática por envolver observar o retorno e comportamento do atendente em diferentes cenários, mas também serão implementados testes automatizados para garantir a robustez do código produzido. Com isso, será possível analisar o sistema desenvolvido tanto quantitativamente, quanto qualitativamente.

Outro ponto relevante que será considerado na execução do trabalho é o desempenho prático do sistema. Como existem muitas ferramentas disponíveis, além da latência natural de servidores Web, banco de dados, ferramentas de RAG e do próprio modelo, todas essas etapas devem ser feitas de modo eficiente, evitando tempos excessivos para enviar as respostas, além de desperdício financeiro dos recursos disponíveis. Dessa forma, busca-se evitar:

- Seguir conversas fora de contexto (gasto desnecessário de tokens e processamento)
- Agente errando na tomada de decisão (perda da qualidade de resposta retornada ao usuário além de maior tempo de processamento e tokens gerados)
- Baixa qualidade nas informações dos imóveis (além do custo de processamento das informações, isso ocasiona mau funcionamento do sistema visto a piora da qualidade no atendimento dos clientes)

Com isso, será possível verificar e balancear diferentes compromissos, como:

- Custos computacionais x qualidade de resposta
- Automação e independência do agente x controle humano

Dessa forma, o sistema será desenvolvido de forma iterativa, permitindo ajustes contínuos ao longo da experimentação.

Métricas de avaliação

Sobre a qualidade do atendimento, as seguintes métricas serão utilizadas:

- Número de agendamentos marcados: Ou seja, o atendente conseguiu conduzir a conversa de modo a levar o cliente até o fim do funil de venda (realizar o agendamento com um vendedor)
- Número de retenção: Percentual de leads “sem interesse” que tiveram suas dúvidas resolvidas com o atendente. Essa métrica vai medir o quão bom o atendente está em fornecer informações e solucionar dúvidas de usuários “curiosos”, que não tem tanta intenção em comprar.
- Tempo de resposta: Será definido um limiar de tempo de resposta do agente, como exemplo, 2 minutos. Mais do que isso significa processamento sendo desperdiçado ou mau funcionamento do agente.
- Uso de ferramentas: Será analisado se o atendente está usando as ferramentas (tools) que foram dispostas. Como exemplo, uma conversa em que o RAG não foi acionado é um sinal preocupante que pode indicar que o modelo está inventando informações sobre os imóveis.

Além disso, critérios “subjetivos” de avaliação também serão utilizados, como exemplo:

- Qualidade da conversa: Avaliação manual feita nas respostas retornadas pelo atendente, de modo a verificar a utilidade e qualidade do sistema.
- Qualidade das informações: Não só as mensagens e o fluxo da conversa será avaliado, mas também a qualidade das informações retornadas pelo modelo. Nesse cenário,

serão avaliados não só o modelo, mas também o sistema de RAG que irá alimentar todo o banco de dados de informações dos imóveis. Isso é importante para garantir que informações corretas sobre o imóvel de interesse sejam retornadas.